PRÉ-PAPER · RASCUNHO

Programação Agêntica no Espaço de Pesos como Alternativa ao Fine-Tuning em Modelos de Linguagem Pequenos

Autores: Luiz Felipe Melo · **Afiliação:** Universidade do Sul de Santa Catarina (Unisul) · **Rascunho:** 13 nov. 2026

Rascunho de trabalho – o estado de cada resultado e o trabalho restante estão listados no final.

TL;DR

- **O defeito.** Modelos pequenos que "pensam" antes de responder costumam ficar presos repetindo a mesma coisa: *"Espera, deixa eu conferir… Sim… Espera…"*. A cada 100 problemas de matemática do ensino fundamental, o Qwen3.5-0.8B fica sem espaço em 85 antes de escrever a resposta.
- **A correção.** Demos a agentes Claude os pesos do modelo e um pequeno orçamento de testes, e pedimos que resolvessem isso editando os pesos diretamente, sem treinamento. **Com quatro edições minúsculas, o modelo passou de 15% para 67% de acerto nos nossos problemas de prática, e de 15,5% para 61,5–67,5% em 200 problemas de um teste trancado (64–68% num segundo teste trancado de 200, com todos os métodos fixados antes da abertura).** Seis execuções de agente sob o mesmo protocolo ficaram todas entre 58% e 67% nos problemas de prática.
- **A comparação.** No nosso orçamento de 12 mil tokens, a edição publicada em *Sparks of Weight-Space Programming* resolve 53,5%, mas ainda está melhorando. Com 20 mil tokens, chega a 65,0%, o mesmo das edições dos agentes (63,5–68,0%), que param de melhorar por volta de 12 mil. O que os dados sustentam é eficiência: o mesmo acerto com 1,7–1,9× menos tokens. As edições dos agentes superam uma receita barata de fine-tuning (29% nos problemas de prática, com 13× mais tempo de GPU).
- **As alternativas simples são fortes.** Limitar o tempo de raciocínio (60–61%), proibir a palavra "Wait" (60,0%) e desligar o raciocínio (58,5%) empatam com a edição do primeiro agente no primeiro teste trancado. O segundo teste trancado, sozinho, não conseguiu separar os métodos. Nos 400 problemas trancados somados, as edições ficam 6,5–9 pontos acima do raciocínio desligado ($p = 0{,}002$–$0{,}02$, sem correção) e 5–7 pontos acima de um limite de raciocínio, mas usam 2,4–3,6× os tokens do raciocínio desligado. Na matemática mais difícil, o raciocínio desligado (44%) empata com as edições sozinhas; só uma edição com limite de raciocínio (53%) fica acima dele ($p = 0{,}035$, sem correção).
- **O que importou.** Agentes independentes voltaram aos mesmos neurônios de "Wait" e à mesma alavanca de `</think>`, mas as edições agem em pontos diferentes: uma reforça um neurônio-freio, outra inverte um neurônio a montante dele, e uma réplica posterior redescobriu sozinha o primeiro mecanismo. Um script simples com as mesmas ferramentas e o mesmo orçamento, mas sem o raciocínio de um agente, não achou. Toda nota rápida que demos aos agentes acabou sendo burlada, e só os testes reais os mantiveram honestos. Em três pares de execuções,

os agentes que receberam mais dados de interpretabilidade acharam correções piores.

- **Onde o método para de funcionar.** Num segundo defeito, espalhado (seguir instruções de formato, IFEval), nem os agentes, nem um system prompt, nem o fine-tuning melhoraram o modelo. Todo candidato que parecia melhor nos testes de prática perdeu de 3 a 7 pontos em prompts novos. O método funciona quando o defeito é concentrado e o efeito é grande. Ele não acha efeitos menores que o próprio ruído de amostragem do teste.

Tudo rodou em uma única placa de vídeo de jogos (GTX 1660 SUPER, 6 GB).



Figura 1: Um problema de prática real, mesma semente aleatória. O modelo original chega à resposta cedo e depois repete "Wait, 120 / 8 = 15" até ficar sem espaço. A versão de 2 edições da correção do segundo agente, a que publicamos (Experimento 2), confere uma vez, fecha o raciocínio e responde. Linha de baixo: o modelo original no primeiro teste trancado; o modelo editado e o modelo sem edição com o raciocínio desligado no segundo (200 problemas cada).

Um modelo pequeno que entra em loop costuma ser tratado como um problema de treinamento: juntar exemplos de bom raciocínio e fazer fine-tuning. Funciona, mas para um modelo que entra em loop até juntar os exemplos sai caro, porque a maioria das tentativas nunca termina.

Recentemente, Takehi et al. mostraram outro caminho. Um modelo de fronteira (o GPT-6 "Astra") leu os pesos brutos deste mesmo modelo e editou 0,016% deles, e o acerto no MATH-500 foi de 7,9% para 48,1%. Queríamos saber três coisas:

1. **Isso se reproduz** numa montagem barata, e o que exatamente aquela edição fez?
2. **É mais do que um truque?** Um ajuste de decodificação ou um fine-tuning comum fariam o mesmo?
3. **O que, no processo do agente, realmente importa?**

O defeito: um modelo que não consegue parar de pensar

O Qwen3.5-0.8B "pensa" num rascunho antes de responder e encerra o raciocínio com um marcador especial, `</think>`. Com um orçamento de 12.288 tokens (cerca de 9.000 palavras), a maioria das respostas nunca chega lá.



Figura 2: Comprimento de cada uma das 48 respostas de prática. A maioria das respostas do modelo original bate no limite de espaço; com a edição do agente, a maioria termina cedo.

Mudar o prompt não ajuda. Um prompt de sistema pedindo que o modelo não se repita não faz melhor do que um prompt placebo sem sentido. Os dois chegam a *aumentar* um pouco a taxa de loop (31% e 30%, contra 23% sem prompt). O loop está nos hábitos do modelo, não nas instruções.

As regras do jogo

Configuração

- **Modelo:** Qwen3.5-0.8B (Qwen Team, 2026), na mesma revisão do estudo original, rodando no llama.cpp (Gerganov et al., 2023).
- **Tarefa:** matemática do ensino fundamental (GSM8K; Cobbe et al., 2021), com raciocínio ligado e orçamento de 12.288 tokens.
- **Edições permitidas:** no máximo 4. Cada edição escolhe um grupo de "neurônios" (colunas de uma matriz de saída em uma camada), uma direção no espaço interno do modelo e uma intensidade. Ela muda apenas o quanto esses neurônios escrevem naquela direção:

$$w_j \leftarrow w_j - \alpha\,(u^\top w_j)\,u, \qquad |\alpha| \le 10.$$

  Em palavras: $\alpha = 1$ apaga essa parte do que os neurônios escrevem, $\alpha > 1$ inverte e $\alpha < 0$ reforça. Cada edição é uma mudança de posto 1.
- **Os agentes recebem:** os pesos, um briefing escrito que descreve o defeito (os loops, com um exemplo) e um avaliador com orçamento fixo. O avaliador oferece 40 "notas rápidas", que medem o quanto o modelo *quer* se repetir sem deixá-lo escrever. Também oferece 6 "testes reais", em que o modelo editado de fato resolve 16 problemas de prática.
- **Não é permitido:** treinar, rodar o modelo fora do avaliador, editar as camadas de vocabulário, nem ler a edição do estudo original, as nossas anotações, o trabalho de outros agentes ou o código do avaliador. Essas regras não foram

impostas por software: auditamos depois cada ação no registro de cada agente e não encontramos violações.

- **Agentes:** Claude Opus 5.5, um por execução, cerca de 2 horas cada. Algumas execuções também receberam um **atlas**: um mapeamento detalhado da atividade interna do modelo enquanto ele entra em loop.
- **Como julgamos:**
  - **Conjunto de prática:** confirmamos a escolha de cada agente em outros 48 problemas (dev48).
  - **Segundo conjunto de prática:** 32 problemas de teste. Já os tínhamos usado em rodadas exploratórias, então não são um teste lacrado.
  - **Teste trancado:** 200 problemas de teste, abertos uma única vez, depois de anotarmos as previsões. Três braços entraram depois e estão marcados.
  - **Matemática mais difícil:** medimos a transferência para 148 problemas de competição (MATH-500; Hendrycks et al., 2021; Lightman et al., 2024) que nenhuma busca tocou.
- **Comparações justas:** todo método responde aos mesmos problemas com as mesmas sementes aleatórias, então dá para contar, problema por problema, quem resolveu o quê.

Um agente consegue corrigir os loops editando pesos?

EXPERIMENTO 1 Conseguimos reproduzir a edição publicada?

A edição publicada muda só duas matrizes, nas camadas 15 e 19. Nós a recuperamos com exatidão. Cada mudança é uma única edição de posto 1 com intensidade 6: ela pega a parte da saída de 64 neurônios que está ao longo de uma "direção de repetição" e a inverte, deixando-a em $-5\times$ o tamanho original. As duas camadas usam quase a mesma direção, escrita por neurônios diferentes.

Na nossa montagem, a edição publicada leva o conjunto de prática de 15% para 46%, e a matemática mais difícil de 8% para 21%. Nossos números absolutos no MATH são menores que os do artigo porque o nosso orçamento de tokens é 12k, e não 32k. Todos os métodos aqui usam o mesmo orçamento. Isso pesa mais para a edição publicada do que para as outras: ela ainda está melhorando quando bate nos 12k, e com 20k tokens alcança as edições dos agentes (veja o teste trancado abaixo).

EXPERIMENTO 2 Um agente Claude consegue encontrar a própria correção?

Nosso primeiro agente (a0) só tinha as notas rápidas. Ele encontrou uma edição diferente, que desencoraja o modelo de copiar "Yes", "?" e "Wait" em duas camadas de atenção, e empatou com a edição publicada no segundo conjunto de prática (44% contra 41%).

Depois acrescentamos os 6 testes reais. **Dois agentes, trabalhando de forma independente, editaram neurônios em comum com a mesma receita em duas partes (suprimir "Wait", reforçar `</think>`), e ela é bem mais forte: 67% e 65% no conjunto**

de prática. Quatro execuções posteriores do mesmo protocolo resolveram 58–65% (veja "Quão repetível é?").

agente	o que a edição faz ($\leq$ 4 edições de posto 1)	conjunto de prática
a1	enfraquece a vontade de dizer "Wait" em 3 neurônios (L17n1915, L18n881, L22n573) e reforça o sinal de `</think>` na última camada	**67%** (26 resgatados, 1 perdido)
a2	inverte o que 4 neurônios escrevem na direção de "Wait" (L16n998, L16n3422 e os L17n1915 e L22n573 do a1) e reforça `</think>` na camada 22	**65%** (24 resgatados, 0 perdidos)

Qual edição do a1 relatamos. O agente a1 ordenou duas variantes da mesma edição: os mesmos neurônios, com intensidades -9 e $-1{,}1$ (a primeira escolha dele) ou -6 e $-0{,}8$ (a segunda). Levamos a variante mais branda, a segunda da lista, a todas as comparações, porque ela foi melhor no conjunto de prática (67% contra 65%). Essa escolha foi nossa, não do agente. No teste trancado as duas são indistinguíveis (61,5% contra 62,0%), e a primeira escolha do agente escreve menos da metade dos tokens. Daqui em diante, "a1" é a variante mais branda, salvo aviso.

Como funciona: os dois agentes leram os pesos "através do vocabulário". Para cada neurônio, perguntaram que palavra ele empurra o modelo a dizer. Foi assim que acharam neurônios que empurram "Wait". As anotações deles mostram que aprenderam com os próprios erros. Negar esses neurônios por completo fez o modelo dizer "wait wait wait…" e não resolver nada, o que lhes mostrou que esses neurônios funcionam ao contrário do que tinham suposto.

As duas partes só funcionam juntas. Nas nossas ablações, cada uma um teste real com 16 problemas:

- o reforço de `</think>` sozinho resolve 19%;
- a supressão de "Wait" sozinha resolve 44–50%;
- as duas juntas resolvem 69%, e quase nada fica sem espaço.

Um loop precisa de um caminho de volta ("Espera, deixa eu conferir") e de nenhuma saída. A edição fecha o primeiro e abre a segunda.

Neurônios em comum, alavancas diferentes. A a1 e a a2 têm dois neurônios em comum e a mesma direção de "Wait", mas a a1 torna a escrita deles $7\times$ mais forte e a a2 a inverte para $-9\times$. Conferimos o que esses neurônios fazem em 12 textos em loop do modelo original:

- **A a1 reforça um freio.** O neurônio L22n573 tem ativação negativa em todas as posições logo antes de um "Wait" (52 de 52), e os pesos de saída dele apontam para "Wait". Ele empurra, portanto, *contra* a palavra, e a a1 amplia esse empurrão. Com o texto fixo, os três neurônios da a1 baixam a log-probabilidade de "Wait" nessas posições em 16,6 nats, e a edição da última camada, sozinha, sobe a de `</think>` em 1,5 nat. As duas partes são separáveis. O L18n881 quase não contribui.

- **A a2 age por um único neurônio a montante.** Ela também baixa "Wait" ali (em 26 nats), e editar só o L16n998 dá o efeito inteiro (−26,2 nats). No modelo original esse neurônio promove "Wait"; depois da edição, ele o suprime. As outras três edições de neurônio quase não mudam nada: L16n3422 e L17n1915 movem "Wait" em menos de 0,3 nat, e a inversão do L22n573, sozinha, *sobe* a palavra em 1,6.
- **Com a edição da camada 16 da a2, o freio se cala.** Dentro do modelo editado pela a2 (e com só os seus dois neurônios da camada 16 editados), a ativação do L22n573 antes de um "Wait" cai de −3,73 para −0,04, e a inversão desse neurônio pela a2 fica quase sem ter sobre o que agir. O freio parece responder a um empurrão a montante na direção de "Wait"; sem o empurrão, ele para de disparar.

Os dois agentes intervêm, então, no mesmo circuito em pontos diferentes: a a1 reforça o freio na camada 22, e a a2 tira o empurrão na camada 16. Essas medidas eram log-probabilidades com o texto fixo, então as conferimos com testes reais nos 48 problemas de prática (com as previsões registradas antes):

- **A a2 funciona como uma correção de 2 edições.** Mantendo só o L16n998 e a edição de `</think>`, o modelo resolve 69% (33 de 48), contra 65% da a2 inteira (6 resgatados, 4 perdidos, $p = 0{,}75$), com respostas mais longas (4.797 tokens contra 3.910; 6 cortadas contra 4). Os outros três neurônios (L16n3422, L17n1915, L22n573) não fizeram diferença mensurável em 48 problemas. No segundo teste trancado, a versão de 2 edições resolve 67,5%, contra 64,0% da a2 inteira (28 resgatados, 21 perdidos; $p = 0{,}39$), e na matemática mais difícil, 47,3% contra 48,6% (12 resgatados, 14 perdidos).
- **Baixar "Wait" não basta para parar.** Só o L16n998, que dava os 26 nats inteiros com o texto fixo, resolve 48% (23 de 48), e 25 de 48 respostas estouram o espaço. Contra a versão de 2 edições, resgata 3 e perde 13 ($p = 0{,}02$). Isso bate com as ablações da a1 acima: num loop, as duas portas precisam mudar.

A Figura 3 descreve a a1.

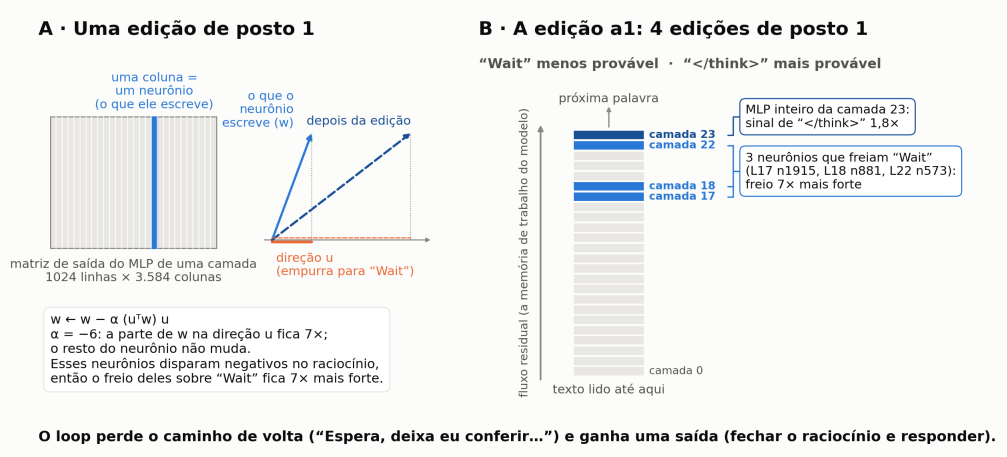


Figura 3: Anatomia da edição a1. (A) Uma edição de posto 1 muda só a parte do que um neurônio escreve numa direção escolhida. (B) A a1 reforça o freio de três neurônios sobre "Wait" e o sinal de `</think>` na última camada.

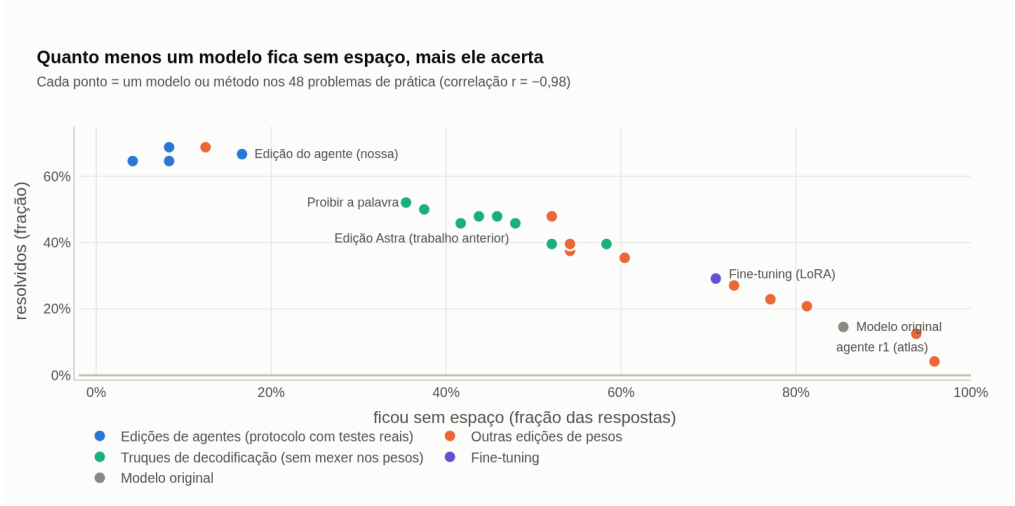


Figura 4: Em 25 modelos e métodos que rodamos no conjunto de prática (sem as execuções exploratórias do Fable), quanto menos respostas ficam sem espaço, mais respostas estão certas ($r = -0{,}98$).

EXPERIMENTO 3 A correção se mantém em problemas que o agente nunca viu?

Na matemática de competição, que nunca foi usada em nenhuma busca, a edição resolve 47%, contra 21% da edição publicada no mesmo orçamento de 12k. Comparada problema por problema com a edição publicada, ela resgatou 44 problemas e perdeu 6. A edição do segundo agente, rodada depois nos mesmos problemas, resolve 49% (43 resgatados e 2 perdidos contra a edição publicada; 18 e 15 contra a a1). No segundo conjunto de prática, a a1 resolve 56% (o original: 13%; a edição publicada: 41%).

Duas ressalvas sobre os números do MATH. Primeiro, a edição publicada ainda fica sem espaço em 78% desses problemas, então os 21% dela são limitados pelo nosso orçamento (o estudo original relata 48% com 32k). Segundo, o nosso corretor de respostas é rígido e deixa passar algumas formas equivalentes. Corrigir os falsos negativos que achamos sobe um pouco todos os métodos e mantém a ordem (a1 49%, a1 + limite de raciocínio 55%, limite de raciocínio 38%, edição publicada 22%). As tabelas usam os números sem correção.

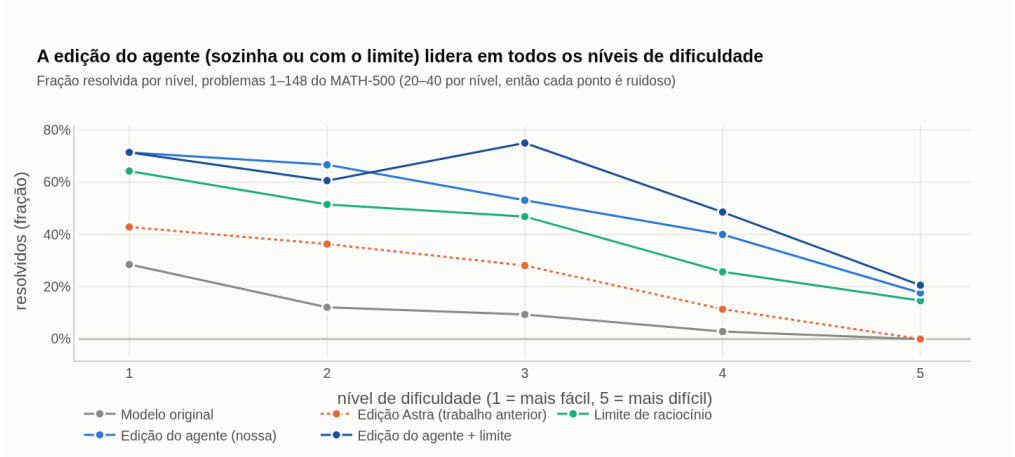


Figura 5: A edição do agente (sozinha ou com o limite de tempo de raciocínio) fica à frente em todos os níveis de dificuldade.

O teste trancado. Abrimos 200 problemas lacrados uma única vez, depois de anotar as previsões. No orçamento cheio de 12.288 tokens, a a1 resolve 61,5% (o original: 15,5%; a edição publicada: 53,5%). Problema por problema, ela vence a edição publicada por **8,0 ± 3,4 pontos** (32 resgates, 16 perdas; $p = 0{,}03$, sem correção).

Mas é o orçamento que decide essa comparação. A tabela mostra a parcela resolvida se cortarmos toda resposta num orçamento menor. Os braços marcados com † rodaram depois de o teste ter sido aberto.

método	2.048	4.096	6.144	8.192	12.288	cortadas em 12k	tokens (média)
modelo original	3,5%	6,5%	10,5%	12,0%	15,5%	84,5%	11.142
edição publicada (Astra)	10,0%	19,0%	24,5%	39,0%	53,5%	42,5%	8.877
fine-tuning (LoRA) †	12,5%	20,5%	26,0%	30,0%	33,0%	65,5%	9.354
proibir a palavra “Wait” †	10,0%	26,5%	41,5%	50,5%	60,0%	35,5%	7.758
limite de raciocínio, 4.096	4,0%	6,5%	60,5%	60,5%	61,0%	34,0%	7.012
limite, resposta com teto de 1.024 †	2,5%	5,0%	60,0%	60,0%	60,0%	35,0% ‡	4.596
edição do agente (a1)	29,0%	45,0%	55,5%	60,5%	61,5%	17,0%	5.049
primeira escolha do agente a1 †	46,5%	60,0%	61,5%	62,0%	62,0%	5,5%	2.269
edição do segundo agente (a2) †	37,5%	53,0%	63,5%	66,5%	67,5%	15,5%	4.387
a1 + limite de raciocínio	25,0%	49,0%	67,5%	69,0%	69,5%	9,5%	4.081
a1 + limite, resposta com teto †	25,5%	54,5%	69,5%	69,5%	69,5%	15,0% ‡	3.172
modelo original, raciocínio desligado †	—	—	—	—	58,5%	5,0%	1.263

‡ Com teto para a resposta, esta coluna conta as respostas interrompidas por esse teto.

- **A edição publicada ainda não estabilizou em 12k.** Ela ganha 14,5 pontos entre 8k e 12k, e 42,5% das respostas dela ainda estão em andamento no teto.
- **As edições dos agentes estabilizam cedo.** A primeira escolha do agente já está em 60% com 4.096 tokens, onde a edição publicada está em 19%.
- **Desligar o raciocínio é a correção mais barata neste benchmark.** O modelo original, assim, resolve 58,5% com cerca de 1.300 tokens por resposta. A a1 com raciocínio fica 3,0 $\pm$ 3,5 pontos acima ($p = 0{,}48$): empate. A a2 fica 9,0 $\pm$ 3,5 acima ($p = 0{,}02$), e a a1 com limite de raciocínio, 11,0 $\pm$ 3,5 acima ($p = 0{,}003$). Com o raciocínio desligado, as edições não ajudam nem atrapalham (a1 56,0%, edição publicada 57,5%).

Todos os valores de p são testes do sinal exatos sobre os pares discordantes, sem correção para múltiplas comparações. Com a correção de Holm sobre as comparações desta seção, a1 contra a edição publicada deixa de ser significativa; a2 contra a edição publicada (14,0 $\pm$ 3,6 pontos; 42 resgates, 14 perdas) e a1 + limite contra o raciocínio desligado continuam sendo.

Com um orçamento maior, a edição publicada alcança

Depois rodamos de novo a edição publicada, a a1 e a a2 no primeiro teste trancado, com teto de 20.480 tokens (pré-registrado; esses braços já tinham sido abertos, então é uma checagem, não um teste novo).

método, teto de 20.480 tokens	4.096	8.192	12.288	16.384	20.480	cortadas em 20k	tokens (média)
edição publicada (Astra)	21,5%	40,0%	51,0%	57,5%	65,0%	18,0%	11.213
edição do agente (a1)	49,5%	63,5%	67,0%	68,0%	68,0%	15,5%	6.608
edição do segundo agente (a2)	51,5%	61,0%	63,0%	63,5%	63,5%	15,0%	5.891

- **Com 20k, as três empatam.** A edição publicada chega a 65,0%, 11,5 pontos acima da rodada de 12k (31 resgates, 8 perdas). Contra a a1 e a a2 com 20k, fica a menos de 3 pontos ($p \geq 0{,}46$). Ela ganha 7,5 pontos entre 16k e 20k, então talvez ainda suba.
- **As edições dos agentes quase não ganham nada depois de 12k** (a2 +0,5 ponto, a1 +1). O teto de 12k não as segurava.
- **A vantagem dos agentes sobre a edição publicada é, portanto, de eficiência, não de acerto.** No mesmo teto de 20k, elas usam 1,7–1,9$\times$ menos tokens; com 8k, já resolvem 61–63,5%, onde a edição publicada resolve 40%.
- **O ruído entre rodadas é de uns 5 pontos, então não dá para ordenar as edições dos agentes entre si.** Cortadas em 12k, as rodadas de 20k deveriam repetir as de 12k. Não repetiram exatamente: a a2 foi de 67,5% para 63,0%, a a1 de 61,5% para 67,0%, e a edição publicada de 53,5% para 51,0%. Mesmas edições, mesmas sementes; o servidor rodou 8 pedidos em paralelo em vez de 16, o que muda a ordem das somas em ponto flutuante e, com ela, as amostras. A a2 estava 6 pontos à frente da a1 na primeira rodada e fica 4,5 atrás na segunda. Juntando

as duas rodadas cortadas em 12k (400 respostas cada), a a1 resolve 64%, a a2 65% e a edição publicada 52%.

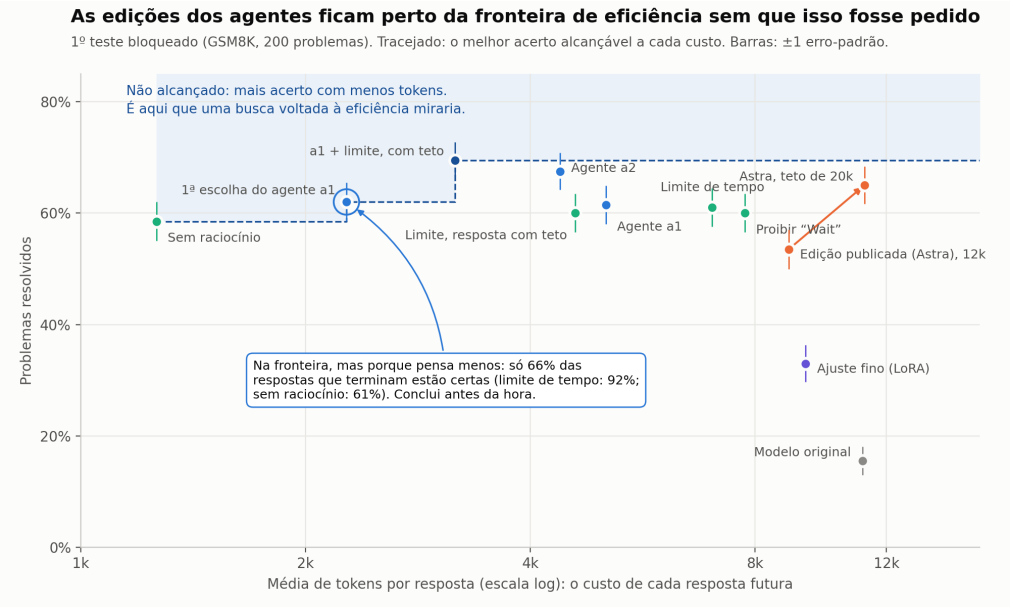


Figura 6: Acerto contra média de tokens por resposta no primeiro teste trancado. A linha tracejada liga os métodos que nenhum outro supera nos dois eixos. Nunca pedimos aos agentes que economizassem tokens, e mesmo assim as edições deles ficam perto dessa linha; a edição publicada só alcança com orçamento de 20k, com cerca do dobro dos tokens. A primeira escolha do agente a1 está na linha porque pensa menos, e mais respostas terminadas dela estão erradas (veja "A cirurgia quebrou alguma coisa?").

Um segundo teste trancado, todo pré-registrado

No primeiro teste trancado, oito braços rodaram depois da abertura. Por isso abrimos mais 200 problemas trancados (GSM8K test[400:600]) com todos os braços, as comparações e as previsões registrados antes, e nada escolhido neles. A análise primária eram cinco comparações pareadas com correção de Holm; a secundária somava os dois testes trancados.

método	segundo teste trancado (200)	cortadas	média de tokens	os dois testes (400)
modelo original, raciocínio desligado	58,0%	7,5%	1.365	58,3%
limite, resposta limitada a 1.024	59,5%	34,5% ‡	4.620	59,8%
edição do segundo agente (a2)	64,0%	15,5%	4.701	65,8%
a1 + limite, resposta limitada	64,5%	15,5% ‡	3.104	67,0%
a2 reduzida a 2 edições	67,5%	12,0%	4.217	—
edição do agente (a1)	68,0%	11,0%	4.459	64,8%

‡ Conta as respostas paradas pelo teto da resposta.

- **Sozinho, o segundo teste não confirma nenhuma das cinco comparações primárias.** Todos os braços editados ficam à frente do raciocínio desligado na direção prevista (a2 +6,0 ± 4,0, a1 + limite com teto +6,5 ± 4,3), mas nenhuma comparação sobrevive à correção (todos os p ajustados por Holm = 0,83). Duzentos problemas não confirmam diferenças de 5–7 pontos. Três das nossas previsões falharam aqui (veja a lista no fim), e a a2 ficou 4,0 pontos atrás da a1 (p = 0,30) depois de estar 6 à frente no primeiro teste, a mesma inversão que vimos depois entre duas rodadas do primeiro teste.
- **Somando os 400 problemas trancados, as edições ficam acima do raciocínio desligado.** A a2 fica 7,5 ± 2,7 pontos acima (74 resgates, 44 perdas; p = 0,007), a a1 + limite com teto 8,8 ± 2,8 (p = 0,002) e a a1 6,5 ± 2,7 (p = 0,02, não pré-registrada). As duas primeiras eram as comparações secundárias pré-registradas; nenhuma tem correção para comparações múltiplas. O raciocínio desligado continua usando só 28–42% dos tokens delas.
- **As edições também ficam à frente do limite de raciocínio.** Nos 400 problemas, a a1 + limite com teto fica 7,2 ± 2,4 pontos acima do limite com teto sozinho (p = 0,004, secundária pré-registrada), e a a1 e a a2 ficam 5,0 e 6,0 pontos acima dele (p = 0,047 e 0,02, não pré-registradas). O empate do primeiro teste agora parece a ponta baixa da faixa.
- **Somar o limite à a1 não ajudou aqui.** A combinação resolveu 64,5% contra 68,0% da a1 sozinha (17 resgates, 24 perdas). Nos dois testes juntos, fica 2,2 ± 2,2 pontos acima da a1 (p = 0,36): não está estabelecido em matemática do ensino fundamental. A a1 foi baixa fora do comum no primeiro teste (61,5%) e alta no segundo (68,0%).

Quão repetível é?

Rodado depois de o primeiro teste trancado ter sido aberto. Nenhuma escolha usou os testes trancados.

Rodamos o protocolo vencedor mais quatro vezes: mais duas com o Claude Opus 5.5 (a3, a4; o editor da a1 e da a2) e duas com o Claude Fable 5.2 (f1, f2). Essas quatro execuções tinham três regras a mais (sem acesso à web, sem ler o repositório deste paper, sem subagentes), e a auditoria dos registros não achou violações. As duas do Fable também foram pausadas e retomadas, e estendemos o orçamento delas depois dos primeiros resultados, então são uma checagem exploratória.

execução	editor	o que a escolha faz ($\leq$ 4 edições de posto 1)	conjunto de prática
a1	Opus	reforça 3 neurônios-freio de “Wait”, mais `</think>`	67%
a2	Opus	inverte o L16n998 (e outros 3 neurônios), mais `</think>`	65%
a3	Opus	inverte uma direção de “hesitação” (“Wait”, “Hmm”, “Actually”…) em quatro camadas inteiras	58%
a4	Opus	reforça 3 neurônios-freio de “Wait” (L18n881, L20n405, L22n573), mais `</think>`	58%
f1	Fable	edições de camada inteira na direção de “Wait” nas últimas camadas	65%
f2	Fable	edições de camada inteira na direção de “Wait” nas últimas camadas	60%

- **As seis execuções consertam o defeito.** Ficam entre 58% e 67% no conjunto de prática (média de 62%), 22 a 26 problemas acima do modelo original e acima da edição publicada (46%). Nenhuma difere da a1 de forma significativa.
- **A a1 e a a2 são o topo dessa faixa, não o centro.** A a3 e a a4 também deixam mais respostas cortadas (25–35%, contra 8–17%) e escrevem mais tokens.
- **A a4 redescobriu sozinha o mecanismo da a1.** Primeiro inverteu os neurônios-freio e obteve “wait wait wait…”, como a a1 e a a2, depois passou a reforçá-los, mantendo o sinal, e acrescentou uma alavanca de `</think>`. A a3 achou os mesmos neurônios, viu pouco efeito em editá-los sozinhos e ficou com uma família mais parecida na forma com a edição publicada e com as execuções do Fable.
- **Uma previsão falhou:** a de que pelo menos uma entre a3 e a4 chegaria a 60% (demos 75%). As duas resolveram 58%, um problema abaixo.

Só a a1, a a2 e a f1 rodaram num teste trancado (f1: 66,0%). Isso mostra que o protocolo produz um ganho grande de forma confiável, por mais de um caminho. Não ordena modelos editores; para isso serve a escada de modelos editores planejada como continuação.

É só um truque?

Um cético perguntaria se a edição é só um jeito sofisticado de fazer algo mais simples. Testamos as alternativas mais simples, ajustadas em 48 problemas (três vezes o que os agentes viram), o que as favorece.

método	prática (48)	segundo conjunto de prática (32)	teste trancado (200)	matemática difícil (148)
modelo original	15%	13%	15,5%	8%
modelo original, raciocínio desligado	—	—	58,5% †	44%
edição publicada (Astra)	46%	41%	53,5%	21%
proibir a palavra “Wait” (melhor de 3 ajustes)	52%	47%	60,0% †	27% (primeiros 48)
limite de raciocínio, 4.096 tokens (melhor de 2)	48%	**63%**	61,0%	37%
limite, resposta com teto de 1.024 (melhor de 3)	50%	—	60,0% †	—
edição por diferença de médias, sem agente (melhor de 6)	—	31%	—	—
busca por script, sem agente	27%	—	—	—
fine-tuning (LoRA)	29%	—	33,0% †	—
edição do agente (a1)	**67%**	56%	61,5%	**47%**
primeira escolha do agente a1	65%	—	62,0% †	—
edição do segundo agente (a2)	65%	—	67,5% †	49%
edição do agente + limite de raciocínio	**69%**	**63%**	**69,5%**	**53%**

† Rodado depois de o teste trancado ter sido aberto; nenhuma escolha dependeu desses braços.

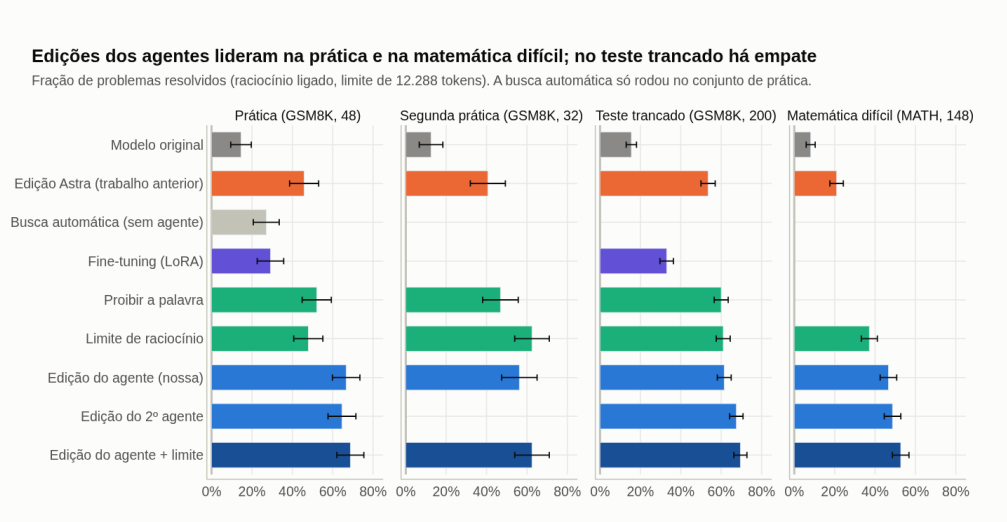


Figura 7: Parcela de problemas resolvidos por cada método nos quatro conjuntos de problemas (barras de erro: ±1 erro padrão).

EXPERIMENTO 4 Um ajuste de decodificação faria o mesmo?

Configuração

- **Proibir a palavra:** enquanto o modelo escreve, tornar "Wait" (e variantes) quase impossível e dar um empurrão em `</think>`. Nenhuma mudança nos pesos.
- **Limite de raciocínio ("budget forcing", Muennighoff et al., 2025):** depois de N tokens de raciocínio, cortar e forçar uma resposta. Nenhuma mudança nos pesos.

Proibir a palavra é pior nos conjuntos de prática e na matemática mais difícil, e empata no teste trancado. Ali ela resolve 60,0%, contra 61,5% da a1 (25 resgates contra 28), com 7.758 tokens por resposta e 35,5% das respostas cortadas. Tínhamos previsto 40–52%. A edição não é uma proibição global. Ela age por meio de neurônios que estão ativos quando o modelo está prestes a recomeçar, então deixa "Wait" em paz no resto.

O limite de raciocínio empata com a edição no primeiro teste trancado (61,0% contra 61,5%; +0,5 ± 3,4), mas não no segundo (a1 68,0% contra 59,5% da versão do limite com teto; 33 resgates, 16 perdas; $p = 0{,}02$, não pré-registrada). A nossa implementação do limite parece mais cara do que é. Depois do `</think>` forçado, algumas respostas continuam em loop até o teto de 12k, e por isso 34% delas são cortadas e a média é de 7.012 tokens. Se cortarmos toda resposta em 6.144 tokens, o limite mantém 60,5% com média de 4.910 tokens, mais ou menos o mesmo que a a1 (5.049). Não afirmamos, portanto, que a edição é mais barata do que um limite bem implementado. Depois rodamos essa versão, com a resposta limitada a 1.024 tokens depois do `</think>` forçado (limite de raciocínio escolhido entre três no conjunto de prática). Ela resolve 60,0% com média de 4.596 tokens, o mesmo acerto do limite sem teto (14 resgates contra 16).

Na matemática mais difícil, a edição fica 9,5 pontos à frente do limite, resgatando 23 problemas e perdendo 9. Forçar uma resposta cedo funciona quando a resposta já tinha sido calculada antes de o loop começar, o que é comum em problemas do ensino fundamental e mais raro nos longos.

Juntos, os dois são o melhor na matemática mais difícil (53%, 6 pontos acima da edição sozinha, embora com só 16 resgates contra 7; $p = 0{,}09$) e no primeiro teste trancado (69,5%, 8 pontos acima de cada um sozinho), com poucas respostas cortadas. A edição tira a maior parte dos loops, e o limite pega o que sobra. No segundo teste trancado, porém, a combinação não superou a a1 sozinha (64,5% contra 68,0%), então, em matemática do ensino fundamental, o ganho sobre a edição não está estabelecido (+2,2 ± 2,2 nos 400 problemas). Uma replicação independente relata a mesma soma em subconjuntos do MATH (tdotlab, 2026). Com o teto para a resposta, a combinação mantém 69,5% no primeiro teste trancado e cai para 3.172 tokens por resposta. Ali, ela fica acima da a1 sozinha (26 resgates, 10 perdas; $p = 0{,}01$), do limite com teto sozinho (33 contra 14; $p = 0{,}008$) e do raciocínio desligado (37 contra 15; $p = 0{,}003$).

Raciocínio desligado. No nosso subconjunto do MATH, com o raciocínio desligado e teto de 8.192 tokens, o modelo original resolve 43,9% (previsto: 38–52%) com 3.842

tokens por resposta, e 36% das respostas ainda batem no teto. A a1 (46,6%) e a a2 (48,6%) ficam 2,7 e 4,7 pontos acima (21 resgates contra 17, p = 0,63; 21 contra 14, p = 0,31): empates. Só a a1 + limite (52,7%) fica acima (23 resgates, 10 perdas; p = 0,035, sem correção). Aqui, desligar o raciocínio economiza menos do que na matemática do ensino fundamental: usa cerca de metade dos tokens da a1, não um terço. Reexecuções independentes relatam cerca de 50% no MATH-500 inteiro com o raciocínio desligado e orçamento de 32k (exp8-loop-controls, 2026). Neste modelo, edições que consertam o raciocínio recuperam, em boa parte, o que o modelo já faz sem raciocinar, mais alguns pontos: nos 400 problemas trancados, os braços editados ficam 6,5–8,8 pontos acima do raciocínio desligado, com 2,4–3,6× os tokens dele; na matemática mais difícil, só a combinação com o limite fica acima (p = 0,035, sem correção).

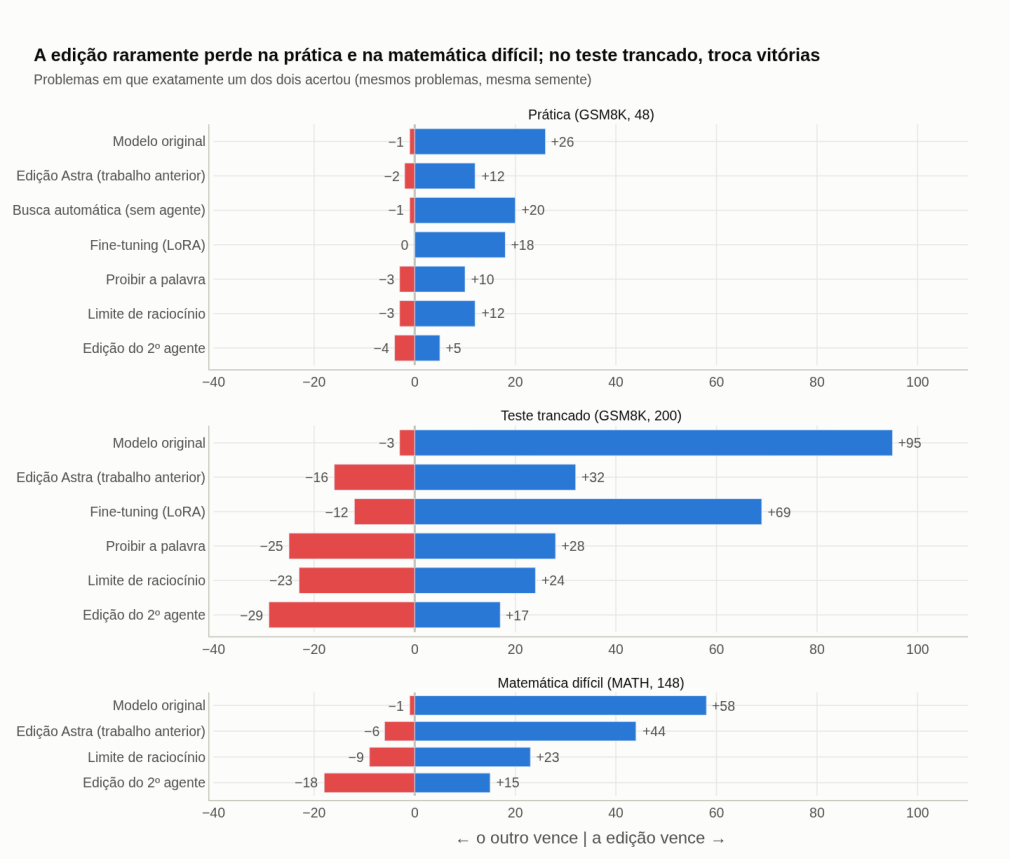


Figura 8: Problema por problema, com os mesmos problemas e sementes: problemas que só a edição do agente resolveu (direita) contra problemas que só o outro método resolveu (esquerda).

EXPERIMENTO 5 Um fine-tuning comum faria o mesmo?

Configuração

- **Dados:** o raciocínio do próprio modelo em 600 *outros* problemas do GSM8K. Só 57 tentativas terminaram de forma limpa e correta. Em 279 que entraram em loop, cortamos o raciocínio onde o loop começou, fechamos o raciocínio e deixamos o modelo responder: 118 respostas estavam certas. Isso dá 175 exemplos de treino.
- **Treinamento:** LoRA (Hu et al., 2022), um método de fine-tuning padrão e barato (posto 16, todas as camadas, 3 rodadas). Escolhemos a melhor rodada nos mesmos 16 problemas que os agentes usaram nos testes reais.

O fine-tuning chegou a 29% no conjunto de prática. É melhor que o original (15%), mas, problema por problema, a edição do agente resgatou 18 problemas que o fine-tuning errou e não perdeu nenhum. O modelo com fine-tuning ainda ficou sem espaço em 71% das respostas (a edição: 17%). Ele aprendeu o que escrever *depois* de um corte, não *quando* parar. Esta é uma receita barata, com 175 exemplos, e não a ajustamos além disso. Mais dados, uma receita de dados melhor ou aprendizado por reforço poderiam fazer melhor, com mais tempo de GPU (veja abaixo). O resultado é "esta receita de fine-tuning perdeu", não "o fine-tuning perde".

No teste trancado, o modelo com fine-tuning resolve 33,0% e ainda fica sem espaço em 65,5% das respostas. A a1 resgata 69 problemas que ele erra e perde 12.

EXPERIMENTO 6 O agente é necessário, ou bastam as ferramentas dele?

Escrevemos um script que testa edições da mesma caixa de ferramentas que os agentes vencedores usaram: "direções de palavras" para as 300 palavras mais comuns, os neurônios mais alinhados a elas e intensidades aleatórias. Ele teve o mesmo orçamento: 40 notas rápidas e mais 6 testes reais com os candidatos mais promissores.

O melhor teste real do script resolveu 3 de 16, e a escolha dele chegou a 27% no conjunto de prática, 40 pontos abaixo dos agentes. Com essa caixa de ferramentas e esse orçamento, escolhas ao acaso não bastaram.

Esta é uma comparação fraca, e existem buscas sem LLM mais fortes:

- **As nossas edições por diferença de médias.** Montamos seis edições a partir da diferença entre o estado interno médio do modelo em textos com e sem loop, sem agente. A melhor resolveu 31% do segundo conjunto de prática, contra 41% da edição publicada e 13% do original: cerca de dois terços do ganho da edição publicada.
- **Trabalhos concorrentes.** Uma direção de diferença de médias recupera 79% do ganho da edição publicada no MATH-500 (Zhang, 2026), e um programa linear chega a cerca de 93% (nathanrs, 2026). Um reparo às cegas, com um modelo editor mais fraco e sem descrição do defeito, não achou nada (WKJBryan, 2026).

Não afirmamos, então, que um agente é necessário. A nossa evidência é mais estreita: os agentes superaram todas as buscas sem agente que *nós* rodamos, e o nosso briefing dizia a eles qual era o defeito.

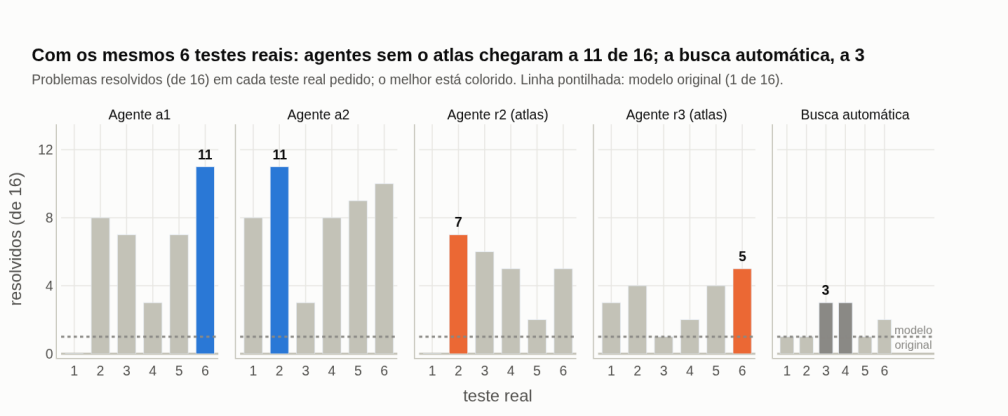


Figura 9: Os 6 testes reais de cada buscador (16 problemas cada). Os dois agentes sem o atlas chegaram a 11 de 16; os agentes com o atlas, a 5–7; o script, a 3.

O que aprendemos sobre o processo

EXPERIMENTO 7 Uma nota rápida pode substituir os testes reais?

Testes reais são lentos (16 problemas levam cerca de 10 minutos na nossa GPU), então a saída óbvia é um indicador rápido. Todo indicador que tentamos quebrou assim que um otimizador forte o pressionou:

- uma edição que pontuou melhor do que a edição publicada na "surpresa" do modelo com palavras de loop ganhou 6 pontos no uso real, contra 28 da edição publicada;
- uma edição sem nenhum loop palavra por palavra ainda ficou sem espaço em 77% das vezes;
- **o agente r1 levou a nota rápida a 20× o valor da edição publicada, e a edição dele resolveu 4% dos problemas, pior do que não fazer nada.** Ela bloqueou a cópia palavra por palavra, e o modelo simplesmente entrou em loop de outras formas (valores alternados, listas crescentes).

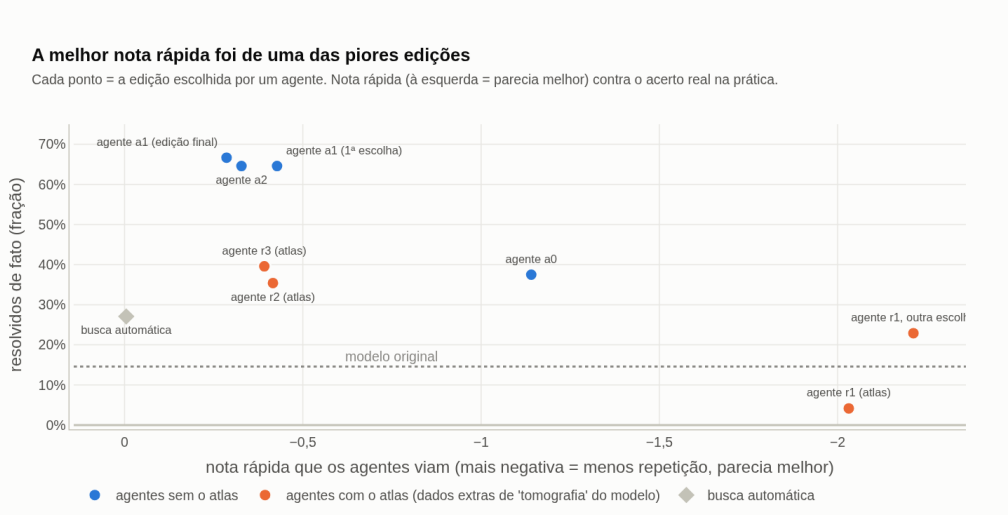


Figura 10: A nota rápida que a edição escolhida por cada agente obteve (à esquerda = parecia melhor) contra o quanto ela de fato resolveu problemas.

Seis testes reais resolveram isso. Nesse protocolo, as primeiras ideias de melhor nota

dos dois agentes resolveram 0 de 16 num teste real, e os agentes as descartaram. **Nossa conclusão: o objetivo de um agente precisa vir do comportamento real, mesmo de uma amostra pequena dele. Indicadores servem como proteção, não como meta.**

EXPERIMENTO 8 Mais dados de interpretabilidade ajudam?

Rodamos três pares de agentes com instruções idênticas; em cada par, um dos agentes também tinha o atlas.

Nos três pares, o agente sem o atlas encontrou a edição melhor (38% contra 4%; 67% contra 35%; 65% contra 40%). Com o atlas, os agentes perseguiram mecanismos internos elaborados, como um estado de "reconferência" nas camadas do meio e "cabeças de loop". Pareciam convincentes nos dados, mas não paravam os loops. Sem ele, os agentes foram direto às alavancas: a palavra "Wait" e o sinal de `</think>`. Três pares tornam isso sugestivo, não comprovado. O primeiro par também rodou no protocolo antigo, sem testes reais, e nos dois primeiros pares tínhamos previsto o resultado oposto.

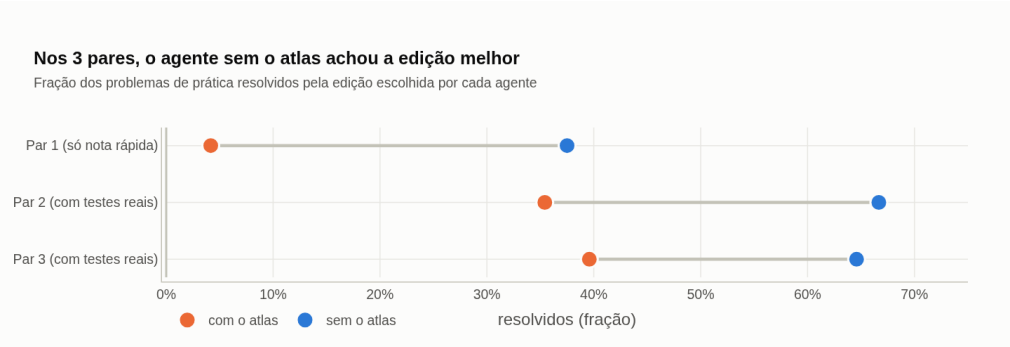


Figura 11: Cada par de agentes teve instruções idênticas; o agente sem o atlas foi melhor todas as vezes.

Quanto custou?

	prática	horas de GPU (1660 SUPER)	uso do agente
edição do agente (uma execução)	**67%**	**1,3** (só a busca)	5,4 M tokens lidos, 48 mil escritos (≈ US$ 5–7 a preço de API)
busca automática	27%	1,6	—
ajuste dos truques de decodificação	48–52%	4,4	—
fine-tuning (LoRA)	29%	17,1	—

- **Custo único.** Uma execução de agente levou cerca de 2 horas, o que dá mais ou menos a energia de um micro-ondas ligado por 15 minutos. O fine-tuning levou 17 horas de GPU, 10 delas só para gerar os dados de treino com um modelo que desperdiça a maior parte das tentativas.
- **Custo de uso.** Contra o modelo original com raciocínio, as respostas do modelo editado são 60% mais curtas no conjunto de prática, 55% no teste trancado e

29% na matemática mais difícil. A primeira escolha do agente a1 é 80% mais curta no teste trancado, e a a1 com o limite com teto é 72% mais curta. Essa economia se repete em cada pergunta. Ela só vale contra o raciocínio ligado: com o raciocínio desligado, o modelo original escreve cerca de 1.300 tokens por resposta, menos que qualquer edição.

- **Comparação com o agente original.** A execução publicada usou 86,8 M tokens lidos e 2,9 M escritos ao longo de 20 horas (segundo os registros públicos). Nosso agente usou 16× e 60× menos, em cerca de 2 horas. As ferramentas são diferentes, então esta não é uma comparação controlada.
- **O que a tabela deixa de fora.** As horas de GPU são só as da busca. Confirmar uma escolha no conjunto de prática custa cerca de 1 hora de GPU a mais, para qualquer método. A linha do agente é uma execução que deu certo. Fizemos dez execuções neste defeito: as três com o atlas foram piores, e as quatro réplicas posteriores do protocolo vencedor resolveram 58–65%.
- **As letras miúdas.** Rodamos com uma assinatura, então os valores em dólar são estimativas a preço de tabela. Numa GPU alugada muito barata, o fine-tuning poderia custar alguns dólares a menos que o uso do agente, entregando menos da metade da melhoria.

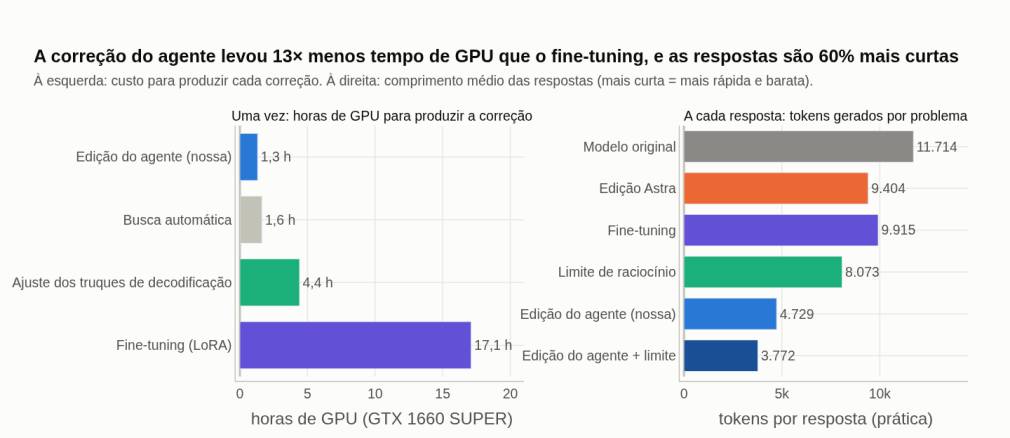


Figura 12: À esquerda, horas de GPU para produzir cada correção. À direita, o comprimento médio das respostas, que define o custo de cada resposta futura.

A cirurgia quebrou alguma coisa?

Com o raciocínio desligado, nenhuma das edições muda o acerto em matemática (200 problemas) ou em chamada de ferramentas (300 pedidos) além de cerca de dois erros padrão. Depois rodamos os mesmos painéis para a a2 e para a versão de 2 edições que publicamos, pareadas com o modelo original: chamada de ferramentas 90,3–91,0% contra 89,7%, matemática 46,0–51,0% contra 48,5%, e chamada de ferramentas com raciocínio 92–94% contra 93%, tudo a menos de um erro padrão. Esses painéis só detectam mudanças de uns 5 a 7 pontos. A edição age onde os loops acontecem, durante o raciocínio, e deixa as outras habilidades em paz até onde conseguimos medir. Há um efeito colateral positivo: com o raciocínio ligado, a edição publicada fica melhor em recusar chamadas de ferramenta irrelevantes (16 de 16 contra 11 de 16), provavelmente porque um raciocínio mais curto deixa menos espaço para inventar uma chamada. As edições dos agentes não têm esse efeito (10–12 de 16).

Um custo: as respostas que terminam erram mais. No teste trancado, 74% das respostas terminadas da a1 estão certas, contra 91% da edição publicada, 92% do limite de raciocínio e 97% do modelo original. Na primeira escolha do agente a1, a edição mais forte, são 66%; na a2, 80%. Parte disso é seleção: o modelo original só termina 31 dos 200 problemas, os fáceis, e as edições terminam também os difíceis.

Para separar as duas coisas, comparamos os métodos só nos problemas que os dois terminam (análise post hoc, não pré-registrada; correção de Holm sobre 8 comparações):

- **Nos 31 problemas fáceis que o original termina,** ele acerta 30; a primeira escolha do agente a1 acerta 26, e a a1, 27.
- **A primeira escolha perde nos problemas terminados em comum.** Contra o limite com teto, resgata 4 e perde 21 ($p = 0{,}001$; Holm 0,008), e contra a edição publicada, 5 e 16 ($p = 0{,}03$, sem correção).
- **O padrão enfraquece junto com o empurrão de `</think>`.** A a1 mostra menos (3 contra 13 diante do limite com teto; $p = 0{,}02$, sem correção), a a2 um pouco (3 contra 10; $p = 0{,}09$), e a f1, cuja edição não tem alavanca de `</think>`, nada (5 contra 3).

Então não é só seleção: as edições que empurram `</think>` com mais força fazem o modelo concluir antes da hora. É o preço do lugar da primeira escolha na fronteira de eficiência (Figura 6).

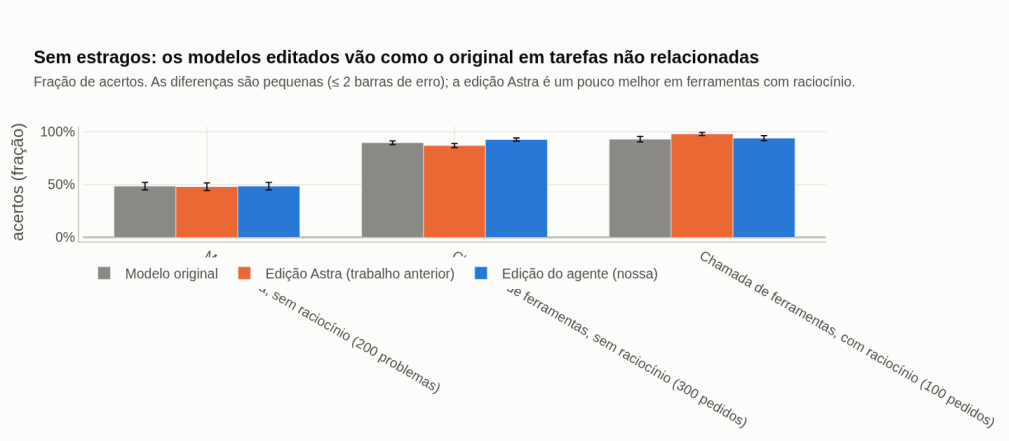


Figura 13: Acerto em tarefas não relacionadas para o modelo original, a edição publicada e a edição do agente.

Funciona num segundo defeito?

Não, e o jeito como falha é informativo. Precisávamos de um defeito sem palavra-chave óbvia. JSON e chamadas de ferramenta quebrados não eram um problema para este modelo com o raciocínio desligado: ele estava perto do teto. Escolhemos então **seguir instruções** (IFEval, Zhou et al., 2023: "não use vírgulas", "tudo em minúsculas", "termine com esta frase exata", "destaque pelo menos 3 seções"). Com o raciocínio desligado, o modelo segue todas as instruções em só cerca de 55% dos prompts, e as falhas se espalham por muitos tipos de instrução.

Configuração

- **Mesmo protocolo dos loops:** um agente com 40 notas rápidas e 6 testes reais por geração, no máximo 4 edições de posto 1.
- **Comparações:** um system prompt pedindo cuidado, e fine-tuning LoRA em 414 respostas do próprio modelo que passaram no verificador oficial (a mesma receita de antes).
- **Confirmação:** em 152–200 prompts do IFEval nunca usados em nenhuma busca.

braço	mudança contra o original em prompts novos
agente, testes de 48 prompts (b1)	$-3{,}3 \pm 4{,}1$
a edição dos loops (a1), sem ajuste para isto	$-3{,}9 \pm 4{,}3$
system prompt	$-6{,}6 \pm 4{,}2$
fine-tuning (época escolhida em 48 prompts)	$-7{,}2 \pm 4{,}3$
agente, testes de 128 prompts (b2)	$-6{,}0 \pm 3{,}7$ (200 prompts)

Todo método pareceu melhor no próprio teste de prática (+5 a +12 pontos) e perdeu em prompts novos. A causa é o ruído de amostragem. Duas execuções do modelo *sem mudança nenhuma*, com sementes diferentes, discordam em 23% dos prompts. Em 48 prompts, isso dá uma margem de erro de 8–9 pontos, maior que qualquer ganho plausível. Um teste maior, de 128 prompts, também não salvou o agente: o controle de sinal oposto da melhor edição também pareceu levemente positivo.

O que isso significa. Nos loops, o efeito era de +46 pontos, e 16 problemas bastavam para vê-lo. Em seguir instruções, mudanças baratas de qualquer tipo (pesos, prompt, gradiente) parecem tirar o modelo de um ponto que já é quase o melhor da vizinhança, e nenhum teste desse tamanho acha as raras mudanças que ajudam. **O alcance do método é dado pela razão sinal/ruído do teste real, não só pelo agente.** Uma receita barata de fine-tuning bate na mesma parede. Nenhum braço aqui difere do original em mais de dois erros padrão, então o resultado é "nada ajudou", não "tudo piorou". Um segundo teste do IFEval, lacrado, continua fechado.

Isso não contradiz o ganho no IFEval relatado para a edição publicada (de 21,0% para 62,3%; Takehi et al., 2026). Esse número é com o raciocínio ligado, em que três quartos das respostas do modelo original nunca fecham o raciocínio e valem zero: é o defeito dos loops de novo. Com o raciocínio desligado, uma reexecução independente mostra que a edição publicada não ajuda ($-2{,}3$ pontos; exp8-loop-controls, 2026), o mesmo que vemos com a a1 ($-3{,}9$).

O agente da segunda execução também achou, só lendo os pesos, uma direção do fluxo residual que 99,7% das linhas dos portões de esquecimento das 288 cabeças DeltaNet (Gated DeltaNet, Yang et al., 2025) leem com o mesmo sinal: um canal global de controle do esquecimento. Editá-la muda o modelo, mas não muda o seguimento de instruções. Fica para trabalho futuro.

Contexto e trabalhos relacionados

Programação no espaço de pesos. Takehi et al. (2026) mostraram que modelos de fronteira conseguem ler e escrever pesos de redes neurais diretamente, incluindo a edição contra loops que reproduzimos. Usamos essa edição como referência e os registros públicos deles na comparação de custo.

Edição de modelos. Edições de posto 1 já foram usadas para mudar fatos armazenados num modelo (ROME, Meng et al., 2022; MEMIT, Meng et al., 2023). Apagar uma única direção pode remover um comportamento como a recusa (Arditi et al., 2024). Nossas edições pertencem a essa família. A diferença é que um agente as escolhe raciocinando sobre o comportamento, em vez de uma fórmula fixa.

Direcionamento (steering). Somar um vetor ao estado interno do modelo durante a execução pode direcionar o seu comportamento (ActAdd, Turner et al., 2023; engenharia de representações, Zou et al., 2023). Nossas edições são permanentes, em vez de aplicadas durante a execução.

Raciocínio excessivo. Modelos de raciocínio costumam reconferir mais do que precisam (Chen et al., 2025). Correções conhecidas incluem suprimir palavras como "Wait" (Wang et al., 2025) e limitar o tempo de raciocínio (Muennighoff et al., 2025). Usamos as duas como alternativas de comparação.

Agentes e Goodhart. Agentes já conduzem experimentos de interpretabilidade (MAIA, Rott Shaham et al., 2024). Otimizadores fortes são conhecidos por burlar objetivos indiretos (Gao et al., 2023; Skalse et al., 2022). Vemos o mesmo com indicadores derivados de interpretabilidade.

Trabalhos concorrentes. O *Sparks* gerou uma onda rápida de trabalhos, por enquanto quase todos preprints e repositórios públicos sem revisão por pares. Hu et al. (2026) rodam 16 trajetórias de edição com o Astra no Qwen3.5-0.8B e no 9B e relatam ganhos grandes no MATH-500 e no IFEval, todos com raciocínio ligado e sem comparações com decodificação ou fine-tuning. Reexecuções independentes da edição do Astra mostram que boa parte do ganho é alcançável sem mexer nos pesos: com o raciocínio desligado e orçamento longo, o modelo original já faz cerca de 50% no MATH-500 e 53–55% no IFEval (exp8-loop-controls, 2026; Zhang, 2026), e uma direção de diferença de médias, achada sem LLM, recupera 79% do ganho no MATH-500 (Zhang, 2026). Uma replicação caseira com Claude como editor, numa GPU de consumo (tdotlab, 2026), achou de forma independente o mesmo neurônio-freio de "Wait" que nossos agentes editaram (camada 22, neurônio 573), e viu que a edição e um orçamento maior se somam de forma quase independente. Nem toda replicação converge: MatinKhajavi (2026) refaz os experimentos com o Claude Opus 5.5 e obtém edições de outro tipo (zerar cabeças de atenção, além do mesmo neurônio 573), e ajaygrover (2026) acha uma direção do Claude quase ortogonal à do Astra, que se soma a ela. Três dos nossos quatro agentes Opus editaram os mesmos neurônios-freio, em pontos diferentes do circuito; o quarto, e as duas execuções com outro modelo editor, usaram edições de camada inteira. Isso combina com o quadro: várias edições diferentes tiram os loops. O IWIBench (von Csefalvay et al., 2026) propõe um benchmark para modelos editores. Nossa contribuição é a comparação controlada: edições de agente contra alternativas de decodificação, de raciocínio desligado e de fine-tuning num teste trancado, com o

acerto relatado por orçamento de tokens, contabilidade de custo, a evidência de que agentes burlam indicadores de interpretabilidade e uma fronteira medida de onde o método para de funcionar.

O que ainda não podemos afirmar, e o que vem a seguir?

- **Tamanho das amostras:** as comparações principais se apoiam em dois testes trancados de 200 problemas ($\pm$3–4 pontos cada, $\pm$2,5 somados), mas os números de desenvolvimento e do MATH ainda se apoiam em 48–148 problemas. O segundo teste trancado, sozinho, não confirmou nenhuma das suas comparações primárias.
- **Um modelo, um defeito que funciona:** "Wait" é uma palavra fácil de mirar, e o segundo defeito (IFEval) deu um resultado negativo bem controlado. **Próximo passo:** um defeito concentrado sem palavra-chave e um segundo modelo. Qualquer segundo defeito precisa de um teste real com ruído bem abaixo do efeito esperado, medido antes da busca.
- **Orçamento de tokens:** a maioria das comparações é com 12.288 tokens. Com 20.480, a edição publicada empata com as edições dos agentes, então a vantagem delas sobre ela é de eficiência, não de acerto. O raciocínio desligado e o limite de raciocínio não foram rodados de novo com 20k.
- **Ruído entre rodadas:** rodar de novo o mesmo braço, com as mesmas sementes, o moveu em até 5,5 pontos quando o lote do servidor mudou. Diferenças desse tamanho entre braços numa única rodada, como a2 contra a1, não são confiáveis.
- **Desligar o raciocínio é uma alternativa forte:** as edições ficam só 6,5–9 pontos acima dela nos 400 problemas trancados, e ela usa 28–42% dos tokens delas. Na matemática mais difícil, ela empata com a a1 e a a2, com metade dos tokens.
- **Braços tardios:** a primeira escolha do agente a1, a a2, o raciocínio desligado, o limite com teto, a a1 com o limite com teto, a proibição da palavra, o fine-tuning e a f1 rodaram no teste trancado depois de ele ter sido aberto. A proibição da palavra e o fine-tuning estavam no pré-registro original e só rodaram tarde. Os outros foram pré-registrados, com previsões, depois da abertura, então a decisão de rodá-los pode refletir o que já tínhamos visto. O limite com teto e a f1 foram escolhidos no conjunto de prática, cada um entre dois ou três candidatos. O segundo teste trancado não tem braços tardios. Todas as comparações ali foram na mesma direção do primeiro, exceto as duas contra a a1 sozinha (a a2, e a a1 + limite com teto), em que a a1 foi melhor.
- **Modelos editores:** as duas execuções do Fable foram uma checagem exploratória e não dizem qual editor é melhor. **Próximo passo:** uma escada de modelos editores, incluindo menores, com várias execuções de cada um sob um só protocolo.
- **Testes reais ruidosos:** os agentes escolhem entre candidatos com 16 problemas, o que não ordena candidatos próximos.
- **A variante da a1 foi escolha nossa:** o agente a pôs em segundo lugar (veja o Experimento 2).
- **Mecanismo:** conferimos o freio da a1 e o neurônio a montante da a2 em 52 posições de 12 textos, com o texto fixo. A a2 reduzida foi testada nos 48 problemas

de prática, no segundo teste trancado e na matemática mais difícil (148), que detectam apenas diferenças grandes.

- **Buscas sem LLM:** a nossa busca por script é uma comparação fraca, e trabalhos concorrentes obtêm a maior parte do ganho da edição publicada sem LLM. **Próximo passo:** um script dirigido (direções lidas pelo vocabulário, o mesmo orçamento) contra os agentes.
- **Respostas terminadas e erradas:** as edições baixam o acerto entre as respostas terminadas. Uma análise post hoc aponta conclusão precipitada, não só seleção, mas não foi pré-registrada (veja os efeitos colaterais).
- **Réplicas:** o protocolo vencedor tem seis execuções (quatro do Opus, duas do Fable), todas em 58–67% no conjunto de prática, mas só três rodaram num teste trancado. A comparação com e sem atlas continua com 3 pares. **Próximo passo:** mais dois pares com e sem atlas.
- **Uma receita de fine-tuning:** uma receita mais forte poderia fechar parte da diferença, a um custo maior.
- **Correção do MATH:** o nosso corretor tem falsos negativos; os números corrigidos estão no texto, não nas tabelas.
- **Múltiplas comparações:** os valores de p não têm correção, salvo aviso.
- **Regras por honra:** as restrições dos agentes foram auditadas, não impostas.
- **Amostrador diferente do estudo original:** os números absolutos mudam, mas toda comparação aqui usa as mesmas configurações.

Previsões que falharam. Anotamos previsões no caderno antes de cada resultado. Estas estavam erradas:

1. A edição com a melhor nota rápida (r1) superaria a edição publicada. Ela resolveu 4%.
2. Uma dose menor das direções do r1 recuperaria o ganho. Não recuperou.
3. O atlas ajudaria. Atrapalhou nos três pares.
4. A edição publicada superaria o limite de raciocínio na matemática mais difícil. O limite venceu (35% contra 21% em 48 problemas).
5. O primeiro agente do IFEval ganharia 5–9 pontos em prompts novos. Perdeu $3{,}3 \pm 4{,}1$.
6. O segundo agente do IFEval, com testes maiores, ganharia 5–15 pontos. Perdeu $6{,}0 \pm 3{,}7$.
7. A a2 faria 52–64% no teste trancado. Fez 67,5%.
8. Pelo menos uma execução do Fable editaria o L22n573 ou outro neurônio-freio de "Wait" nas camadas 17–23. Nenhuma mirou neurônios isolados; as duas editaram camadas inteiras.
9. Proibir a palavra faria 40–52% no teste trancado. Fez 60,0%.
10. A a1 + limite com teto venceria o raciocínio desligado com $p < 0{,}05$ no segundo teste trancado (70%). Ficou 6,5 pontos à frente, $p = 0{,}17$.
11. A a1 faria 55–67% no segundo teste trancado. Fez 68,0%.
12. A a2 reduzida usaria pelo menos tantos tokens quanto a a2 ali (60%). Usou 10% menos.
13. Com o raciocínio desligado, a matemática mais difícil usaria menos de um terço dos tokens da a1 (85%). Usou 46%.

14. Pelo menos uma das duas réplicas do Opus (a3, a4) chegaria a 60% no conjunto de prática (75%). As duas resolveram 58%.

A afirmação, como está hoje: para um defeito de comportamento concentrado e de efeito grande, um agente editando pesos achou uma correção em cerca de 2 horas numa GPU de consumo, e seis execuções do mesmo protocolo acharam uma. Nos 400 problemas trancados, as comparações pré-registradas põem as edições 7,5–9 pontos acima do raciocínio desligado, e a edição com limite 7 pontos acima do limite sozinho ($p = 0{,}002$–$0{,}007$, sem correção), embora o raciocínio desligado use muito menos tokens. A edição publicada só chega ao mesmo acerto com orçamento de 20k, usando 1,7–1,9$\times$ os tokens. A edição do agente soma-se a um limite de raciocínio na matemática mais difícil e superou a única receita de fine-tuning que testamos. Para defeitos espalhados, como seguir instruções num modelo de 0,8B, nem ela nem um fine-tuning barato ajudaram.

Dados, código e registros

Está tudo no repositório do projeto:

- **Caderno de laboratório:** datado, com as previsões escritas antes dos resultados (`docs/CADERNO.md`).
- **Registros de cada execução de agente:** briefings, anotações, registros do avaliador e cada edição submetida (310).
- **Figuras:** `notebooks/results.ipynb`, o notebook que desenha cada gráfico deste texto.
- **Custo:** um estudo detalhado (`docs/cost.md`).

As transcrições completas dos agentes e as gerações brutas (~210 MB) serão publicadas após revisão.

Uso de ferramentas de IA

Os agentes editores estudados aqui são o Claude Opus 5.5 e, em duas execuções posteriores, o Claude Fable 5.2. O Claude (Opus 5.5 e Fable 5.2, pelo Claude Code) também foi usado como assistente de pesquisa em todo o trabalho: escreveu a maior parte do código, rodou os experimentos, manteve o caderno de laboratório, redigiu este texto e fez uma revisão independente das afirmações contra os dados brutos. O autor desenhou o estudo, supervisionou e conferiu o trabalho, e é responsável pelo conteúdo.

Estado deste rascunho e plano até a submissão

	estado
Reprodução e dissecação da edição publicada	feito
6 execuções de agente (2 protocolos, 3 pares com e sem atlas)	feito
Alternativas de decodificação, busca ingênua, fine-tuning	feito
Transferência para matemática mais difícil, efeitos colaterais, custo	feito
Teste trancado com $\geq$ 200 problemas	feito (7 braços pré-registrados antes da abertura, 2 rodados tarde; 6 acrescentados e pré-registrados depois)
Segundo teste trancado, todos os braços pré-registrados (GSM8K test[400:600])	feito (12 nov.): 6 braços; a direção se repete em 3 das 4 comparações primárias que também rodaram no primeiro teste (a2 $\times$ a1 se inverteu); nenhuma significativa sozinha
Mais réplicas do protocolo vencedor	feito (13 nov.): a3 e a4 (Opus), 58% cada; seis execuções em 58–67%
Efeitos colaterais da a2 e da a2 reduzida	feito (13 nov.): nenhum detectado
Terminadas e erradas: seleção ou conclusão precipitada?	feito post hoc (13 nov.): em parte, conclusão precipitada
Figura de abertura e fronteira de eficiência	feito (13 nov.): Figuras 1 e 6
Mais pares com e sem atlas	a fazer
Segundo defeito sem palavra-chave (IFEval)	feito: negativo, com comparações de fine-tuning e de prompt
Segundo defeito concentrado; segundo modelo	a fazer (necessário para uma conferência principal)
Recorrigir o MATH com um verificador simbólico	em parte (falsos negativos corrigidos à mão; números no texto)
Diagrama da anatomia da edição	feito (Figura 3)
Raciocínio desligado no teste trancado (teto de 8k)	feito (10/11): 58,5%, empata com a a1
Raciocínio desligado, a2 e a2 reduzida na matemática mais difícil (148)	feito (12/11): 43,9%, 48,6%, 47,3%; só a a1 + limite fica acima do raciocínio desligado (p = 0,035, sem correção)
Revisão independente de cada afirmação contra os dados	feito (10/11); este rascunho a aplica
Conferência do mecanismo nas ativações	feito para a a1 e a a2 (11 nov.)
Edição publicada, a1 e a2 com orçamento longo (20k)	feito (13 nov.): 65,0%, 68,0%, 63,5%; empate
Limite de raciocínio com teto para a resposta	feito (11 nov.): 60,0% sozinho, 69,5% com a a1
Execuções exploratórias com outro editor (Claude Fable 5.2)	feito (11 nov.); menção breve
Escada de modelos editores sob um só protocolo	a fazer (estudo seguinte)
Figuras 7 e 8 com os braços novos	feito (11 nov.); as Figuras 5 e 12 não têm braços novos
Conferir as citações	feito (10/11; as 16 existem, 6 corrigidas, 5 acrescentadas)

Onde publicar: primeiro um preprint no arXiv; depois um workshop de interpretabilidade ou de agentes de LLM com os resultados atuais; e uma conferência principal se um segundo defeito concentrado funcionar.

Títulos alternativos: *Agentes como Programadores do Espaço de Pesos: Corrigindo Loops de Raciocínio em Modelos de Linguagem Pequenos*; *Geração no Laço: o que Faz a Programação Agêntica no Espaço de Pesos Funcionar*.

Glossário

- **Modelo de linguagem, pesos:** o modelo é uma grande coleção de números (os *pesos*) organizados em matrizes. O Qwen3.5-0.8B tem cerca de 800 milhões deles. Treinar muda os pesos aos poucos, com gradientes. Aqui, um agente muda poucos pesos de forma direta e deliberada.
- **Token:** o pedaço de texto que o modelo lê e escreve de cada vez, cerca de ¾ de uma palavra.
- **Raciocínio (“thinking”), loop:** antes de responder, o modelo escreve um rascunho entre `<think>` e `</think>`. Ele está em *loop* quando repete o mesmo trecho (“Espera, deixa eu conferir…”) até esgotar o espaço.
- **Edição de posto 1 (rank-1):** a menor mudança estruturada numa matriz. Ela escolhe uma direção e um grupo de *neurônios* (colunas da matriz) e muda só o quanto esses neurônios escrevem naquela direção. Cada correção usou no máximo 4 dessas edições.
- **Fine-tuning, LoRA:** o caminho usual, que é treinar o modelo com exemplos. LoRA é a versão barata, que treina só pequenas matrizes acrescentadas ao modelo.
- **Steering (direcionamento):** somar um vetor às ativações internas para empurrar o comportamento. A edição Astra é desse tipo, só que gravada nos pesos.
- **Decodificação:** como o texto é sorteado a partir das probabilidades do modelo. *Proibir a palavra* (logit bias) e *limite de raciocínio* (budget forcing) mudam a decodificação, não os pesos.
- **Agente:** um modelo de IA (aqui, Claude) que trabalha sozinho com ferramentas: lê os pesos, propõe edições, pede avaliações e decide o próximo passo.
- **Nota rápida (sonda) e teste real:**
  - a nota rápida mede, em segundos, uma probabilidade interna (por exemplo, o quanto o modelo “quer” repetir);
  - o teste real faz o modelo editado de fato resolver problemas e confere as respostas. Lição central: notas rápidas podem ser burladas, e só o teste real é confiável.
- **Conjunto de prática, teste trancado, pré-registro:** os agentes só viam 16 problemas de prática; confirmamos as escolhas deles em outros 48. O *teste trancado* fica lacrado até que cada método tenha escolhido sua versão final. As previsões foram escritas no caderno *antes* de abrir os resultados (pré-registro).
- **Erro-padrão (± EP), comparação pareada:** “+8,0 ± 3,4” quer dizer um ganho de 8 pontos com incerteza de cerca de 3,4. Uma diferença maior que ~2 EP raramente é sorte. Na comparação pareada, os dois métodos fazem os *mesmos*

problemas: *resgates* são os que só o primeiro acerta, e *perdas*, os que só o segundo acerta.

- **GSM8K, MATH-500, IFEval:** conjuntos públicos de avaliação.
  - GSM8K: matemática do ensino fundamental.
  - MATH-500: matemática de competição.
  - IFEval: seguir instruções verificáveis ("sem vírgulas", "tudo em minúsculas"…).
- **Lei de Goodhart:** quando uma medida vira meta, ela deixa de ser uma boa medida. É o que aconteceu com as notas rápidas.
- **Atlas:** um mapa extra da atividade interna do modelo (quais neurônios disparam em loops), dado a metade dos agentes.
- **DeltaNet:** o tipo de camada ("atenção linear") que forma 18 das 24 camadas do Qwen3.5. Ela guarda uma memória resumida do texto e tem *portões* que decidem o quanto esquecer.

Referências

- ajaygrover (2026). weight-space-programming-stacking. GitHub repository, https://github.com/ajaygrover/weight-space-programming-stacking. Accessed Nov. 10, 2026.
- Arditi, A., Obeso, O., Syed, A., Paleka, D., Panickssery, N., Gurnee, W., Nanda, N. (2024). Refusal in Language Models Is Mediated by a Single Direction. NeurIPS 2024. arXiv:2406.11717.
- Chen, X., Xu, J., Liang, T., He, Z., et al. (2025). Do NOT Think That Much for 2+3=? On the Overthinking of Long Reasoning Models. ICML 2025, PMLR 267. arXiv:2412.21187.
- Cobbe, K., Kosaraju, V., Bavarian, M., Chen, M., et al. (2021). Training Verifiers to Solve Math Word Problems. arXiv:2110.14168.
- exp8-loop-controls (2026). Pre-registered controls for Experiment 8 of Sparks of Weight-Space Programming. GitHub repository, https://github.com/1099271/exp8-loop-controls. Accessed Nov. 10, 2026.
- Gao, L., Schulman, J., Hilton, J. (2023). Scaling Laws for Reward Model Overoptimization. ICML 2023. arXiv:2210.10760.
- Gerganov, G., and contributors (2023–). llama.cpp. Software. https://github.com/ggml-org/llama.cpp.
- Hendrycks, D., Burns, C., Kadavath, S., Arora, A., Basart, S., Tang, E., Song, D., Steinhardt, J. (2021). Measuring Mathematical Problem Solving With the MATH Dataset. NeurIPS 2021 Datasets and Benchmarks Track. arXiv:2103.03874.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022. arXiv:2106.09685.
- Hu, J., Tang, C., Li, W., Zhu, H., et al. (2026). Exploring Weight-Space Programming: Capabilities, Generalization, and Limitations. arXiv:2611.09382.
- Lightman, H., Kosaraju, V., Burda, Y., Edwards, H., et al. (2024). Let's Verify Step by Step. ICLR 2024. arXiv:2305.20050.
- MatinKhajavi (2026). Weight-Space-Programming: a replication with Claude Opus 5.5. GitHub repository, https://github.com/MatinKhajavi/Weight-Space-Programming. Accessed Nov. 10, 2026.
- Meng, K., Bau, D., Andonian, A., Belinkov, Y. (2022). Locating and Editing Factual Associations in GPT. NeurIPS 2022. arXiv:2202.05262.

- Meng, K., Sen Sharma, A., Andonian, A., Belinkov, Y., Bau, D. (2023). Mass-Editing Memory in a Transformer. ICLR 2023. arXiv:2210.07229.
- Muennighoff, N., Yang, Z., Shi, W., Li, X. L., Fei-Fei, L., et al. (2025). s1: Simple test-time scaling. EMNLP 2025. arXiv:2501.19393.
- nathanrs (2026). weight-space-lp. GitHub repository, https://github.com/nathanrs/weight-space-lp. Accessed Nov. 10, 2026.
- Qwen Team (2026). Qwen3.5: Towards Native Multimodal Agents. Blog post, https://qwen.ai/blog?id=qwen3.5. Model: https://huggingface.co/Qwen/Qwen3.5-0.8B.
- Rott Shaham, T., Schwettmann, S., Wang, F., Rajaram, A., Hernandez, E., Andreas, J., Torralba, A. (2024). A Multimodal Automated Interpretability Agent. ICML 2024. arXiv:2404.14394.
- Skalse, J., Howe, N. H. R., Krasheninnikov, D., Krueger, D. (2022). Defining and Characterizing Reward Gaming. NeurIPS 2022. arXiv:2209.13085.
- Takehi, R., Teoh, J., Zhang, A., Khattab, O. (2026). Sparks of Weight-Space Programming: LLMs Can Natively Read & Write Neural Network Weights. Blog post, MIT CSAIL, Nov. 2, 2026. https://rikiyat.github.io/blog/weight-space-programming/. Logs: https://github.com/RikiyaT/lm_understand-logs.
- tdotlab (2026). weight-space-programming: a home replication with a Claude editor. GitHub repository, https://github.com/tdotlab/weight-space-programming. Accessed Nov. 10, 2026.
- Turner, A. M., Thiergart, L., Leech, G., Udell, D., Vazquez, J. J., Mini, U., MacDiarmid, M. (2023). Steering Language Models With Activation Engineering. arXiv:2308.10248.
- von Csefalvay, C., Doma, P., Unni Krishnan, A. (2026). IWIBench: Evaluating Gradient-Free Model Driven Intra-weight Injection. arXiv:2611.08647.
- Wang, C., Feng, Y., Chen, D., Chu, Z., Krishna, R., Zhou, T. (2025). Wait, We Don't Need to "Wait"! Removing Thinking Tokens Improves Reasoning Efficiency. Findings of EMNLP 2025. arXiv:2506.08343.
- WKJBryan (2026). wsp-lab. GitHub repository, https://github.com/WKJBryan/wsp-lab. Accessed Nov. 10, 2026.
- Yang, S., Kautz, J., Hatamizadeh, A. (2025). Gated Delta Networks: Improving Mamba2 with Delta Rule. ICLR 2025. arXiv:2412.06464.
- Zhang, Y. (2026). Rethinking Weight-Space Programming. Blog post and repository, https://github.com/ZhangYiqun018/rethinking-weight-space-programming. Accessed Nov. 10, 2026.
- Zhou, J., Lu, T., Mishra, S., Brahma, S., Basu, S., Luan, Y., Zhou, D., Hou, L. (2023). Instruction-Following Evaluation for Large Language Models. arXiv:2311.07911.
- Zou, A., Phan, L., Chen, S., Campbell, J., et al. (2023). Representation Engineering: A Top-Down Approach to AI Transparency. arXiv:2310.01405.

Anotações, dúvidas e sugestões